AutoML para Previsão da Produção de Arroz na América do Sul

Atividade Prática 1, SCC0233: Aplicações de Aprendizado de Máquina e Mineração de Dados

Renato Spessotto, 14605824

30 de agosto de 2026

Resumo

Este relatório revisita o problema de previsão da produção anual de arroz na América do Sul estudado por Grion et al. [2026]. A configuração manual de modelos (Regressão Linear, SVR e XGBoost) foi substituída por AutoML com o AutoGluon-Tabular [Erickson et al., 2020]. Com os mesmos dados (FAOSTAT e NASA POWER) e os mesmos cenários do artigo, o AutoGluon superou o XGBoost manual em três dos quatro cenários: MAPE de 7,20% contra 13,72% no holdout agrícola, e de 5,05% e 6,55% contra 12,47% e 11,30% na validação cruzada. No quarto cenário, o holdout com clima, ficou empatado com o XGBoost (8,99% contra 8,79%, valor aproximado). O relatório também abre a caixa-preta: mostra a composição do ensemble, o erro de teste de cada modelo, a importância dos atributos, a sensibilidade ao preset e ao tempo, a variação entre sementes e o custo computacional.

1 Introdução

O artigo de referência [Grion et al., 2026], "Predictive Modeling of Rice Production in South America Using Machine Learning" (SBSI 2026), prevê a produção anual de arroz em 12 países da América do Sul a partir de dados agrícolas da FAOSTAT [FAOSTAT, 2025] e climáticos da NASA POWER [Stackhouse et al., 2018]. Ele compara Regressão Linear, SVR e XGBoost configurados manualmente e aponta o XGBoost como o modelo mais equilibrado, com MAPE entre aproximadamente 9% e 14%, conforme o cenário.

O objetivo desta atividade é investigar se uma abordagem de AutoML consegue resultados competitivos com os do estudo de referência, automatizando a seleção de algoritmo e o ajuste de hiperparâmetros, sem tratar a ferramenta como caixa-preta. Todo o código, as tabelas e as figuras deste relatório foram gerados no notebook `rice_automl.ipynb`, entregue junto com este documento.

2 Trabalho de referência

O estudo original usa dados da FAOSTAT (2004 a 2023) e da NASA POWER (2011 a 2023) para os 12 países da América do Sul. Os atributos são *Area harvested (ha)* e *Yield (kg/ha)* e, na versão com clima, a temperatura média e a precipitação anuais; o alvo é *Production (t)*. Os autores testam janelas de treino de 5, 10 e 15 anos e concluem que 10 anos oferecem o melhor equilíbrio entre abrangência e atualidade. Os resultados usados aqui como referência estão na Tabela 1.

Tabela 1: MAPE (%) reportado no artigo original, por cenário e modelo.

Cenário	Atributos	Regressão Linear	SVR	XGBoost
Holdout 3 anos (2021–2023)	agrícolas	32,38	121,15	13,72
Holdout 3 anos (2021–2023)	+ clima	2,13*	13,00*	8,79*
Validação cruzada $k = 5$	agrícolas	34,87	137,23	12,47
Validação cruzada $k = 5$	+ clima	34,60	121,00†	11,30

*Valores aproximados a partir do texto do artigo, que não publica um MAPE agregado de 3 anos para o cenário com clima. Regressão Linear: média dos erros anuais de 2021, 2022 e 2023 (0,76%, 3,94% e 1,69%). XGBoost: média de 4,37% (2021) com os valores de 2022 e 2023, descritos apenas como "cerca de 11%". SVR: ponto médio da faixa de erro relatada para o período (9% a 17%), sem valor pontual por ano.

†O artigo relata apenas que o SVR na validação cruzada com clima "superou 120%", sem publicar o valor exato; 121,00 é usado aqui como aproximação para permitir a comparação numérica.

3 Configuração experimental

Usamos o dataset que já integra FAOSTAT e NASA POWER, do repositório oficial do artigo [Grion, 2026] (`dataset_NASA_FAOSTAT.csv`): 12 países no período de 2011 a 2023, num total de 156 observações, sem valores ausentes.

Ferramenta. Escolhemos o AutoGluon-Tabular [Erickson et al., 2020] por três motivos:

- treina uma família ampla de modelos: LightGBM, CatBoost, XGBoost, Random Forest, Extra Trees, KNN, redes neurais e modelos lineares;
- combina esses modelos com *bagging* em k folds e *stack ensembling* em várias camadas. Num dataset pequeno, isso garante que cada modelo seja avaliado fora da amostra;
- oferece ferramentas de inspeção: um *leaderboard* com o erro de validação e de teste de cada modelo, os pesos do ensemble, os hiperparâmetros e a importância por permutação.

Cenários. Replicamos os dois eixos centrais de comparação do artigo original:

- **Cenário A, holdout temporal:** treino em 2011–2020, teste em 2021–2023, sem e com variáveis climáticas.
- **Cenário B, validação cruzada $k = 5$:** sobre 2011–2023, também sem e com clima, reportando o MAPE médio e o desvio-padrão entre folds.

Configuração do AutoGluon. Cada execução treina um `TabularPredictor` do zero com:

- `eval_metric="mean_absolute_percentage_error"`, otimizando diretamente a métrica do artigo;
- `presets="best_quality"`;
- 120 s de orçamento no Cenário A e 60 s por fold no Cenário B.

A variável `Pais` entra como categórica, e o pré-processamento fica a cargo da ferramenta. O preset e o tempo foram escolhidos por um estudo de sensibilidade (Seção 4.1.1). Para medir a variabilidade, o Cenário A foi repetido com três sementes (42, 7 e 2026). Reportamos o MAPE (Eq. 1), obrigatório, e também MAE, RMSE e R^2.

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \tag{1}$$

4 Resultados

4.1 Processo do AutoML

Nos dois conjuntos de atributos, o modelo final foi um `WeightedEnsemble_L3`: uma média ponderada, com pesos ajustados nas predições *out-of-fold*, de modelos de duas camadas de *stacking*. A Tabela 2 mostra os principais modelos do *leaderboard*, com o MAPE de validação, que guiou a seleção, e o de teste, que só foi calculado depois.

Tabela 2: Leaderboard do AutoGluon no Cenário A (agrícola), ordenado pela validação. Em negrito, o modelo selecionado.

Modelo	Camada	MAPE validação (%)	MAPE teste (%)
WeightedEnsemble_L3	3	**4,34**	**7,20**
WeightedEnsemble_L2	2	4,41	6,89
RandomForestMSE_BAG_L2	2	5,24	8,93
ExtraTreesMSE_BAG_L1	1	5,49	8,65
RandomForestMSE_BAG_L1	1	8,18	11,67
NeuralNetTorch_BAG_L1	1	8,51	25,44
XGBoost_BAG_L1	1	8,68	10,01
CatBoost_BAG_L1	1	15,26	18,84

Composição do ensemble. No cenário agrícola, o ensemble final dá 56% do peso a um Extra Trees com *bagging*, 19% a uma rede neural, 12% a um Random Forest da camada 2 e 6% cada a LightGBM e CatBoost. Com clima, o Extra Trees fica com 36%, o Random Forest da camada 2 com 32%, uma rede neural com 20% e o CatBoost com 12%. Os hiperparâmetros do Extra Trees são os padrões da ferramenta (300 árvores, `max_leaf_nodes`=15000). O ganho vem da combinação de modelos, não de uma busca fina de hiperparâmetros.

Validação versus teste. Duas observações saem do *leaderboard*:

- a validação é otimista. O MAPE de validação do modelo escolhido (4,3%) fica abaixo do de teste (7,2%), porque a validação *out-of-fold* mistura anos, enquanto o teste é o futuro;
- a terceira camada não se pagou. O `WeightedEnsemble_L2`, com uma camada a menos, teve teste um pouco melhor (6,89%). E modelos com erro alto no teste, como a rede neural (25%), receberam peso no ensemble, porque a seleção é feita pela validação.

Importância dos atributos. A importância por permutação no teste (Figura 1) mostra que *Area harvested* domina: embaralhá-la piora o MAPE em mais de 200 pontos percentuais. Em seguida vêm *Yield* e o país. Com clima, a importância de `Pais` dobra (de 14 para 29 p.p.) e a temperatura ganha algum peso (12 p.p.), sem que o erro de teste melhore. É um sinal de que, com apenas 13 observações por país, as variáveis climáticas ajudam a identificar o país mais do que a explicar a produção.

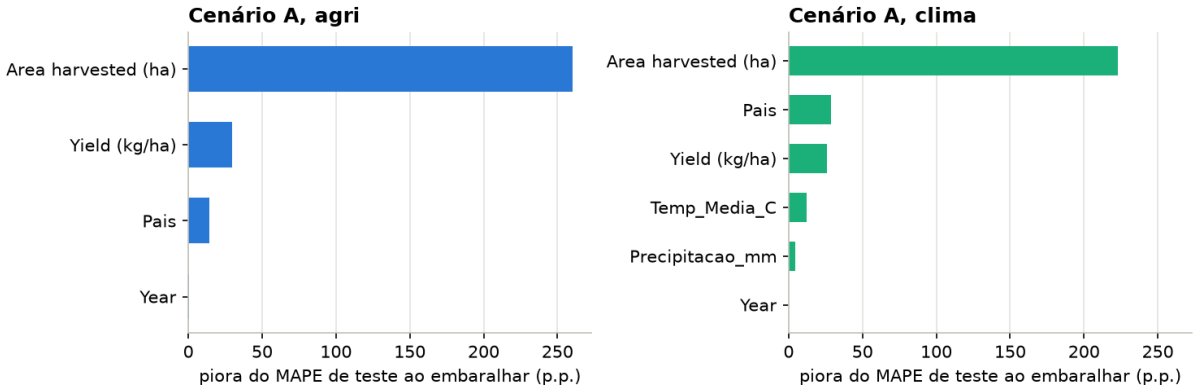


Figura 1: Importância por permutação no teste: piora do MAPE ao embaralhar cada atributo (Cenário A).

Baseline manual. Uma Regressão Linear padronizada (`StandardScaler` e *one-hot* do país), no mesmo split, obteve MAPE de 24,3% (agrícola) e 25,0% (com clima). É a mesma ordem da Regressão Linear agrícola do artigo, mas muito distante dos 2,13% reportados para o cenário com clima.

4.1.1 Sensibilidade ao preset e ao tempo

A Tabela 3 compara três presets com orçamentos de 30, 60 e 120 s no Cenário A agrícola.

- `best_quality` e `high_quality` melhoram com o tempo: com 30 s mal começam o *stacking*, e com 120 s chegam a cerca de 7%.
- `medium_quality`, sem *bagging*, termina em cerca de 22 s e teve o menor MAPE de teste nesta execução (6,05%). Essa diferença é menor que a variação entre sementes do próprio `best_quality` (6,0% a 8,1%).

O preset não foi escolhido pelo teste, o que seria usar o teste para selecionar o modelo. Mantivemos o `best_quality` com 120 s, que valida todos os modelos fora da amostra: é a estimativa mais confiável com 120 linhas de treino.

Tabela 3: Sensibilidade ao preset e ao `time_limit` (Cenário A, agrícola): MAPE de teste (%).

Preset	30 s	60 s	120 s
`medium_quality`	6,05	6,05	6,05
`high_quality`	11,66	8,75	7,11
`best_quality`	11,54	8,54	7,20

Variabilidade entre sementes. Com as sementes 42, 7 e 2026, o MAPE de teste do Cenário A foi de $7{,}12 \pm 1{,}06\%$ (agrícola) e $8{,}09 \pm 1{,}06\%$ (com clima). Diferenças abaixo de cerca de 1 ponto percentual não são conclusivas com 36 pontos de teste.

4.2 Desempenho preditivo

No Cenário A, o modelo agrícola tem R^2 de 0,994. O erro por ano é de 5,0% em 2021, 10,2% em 2022 e 6,4% em 2023. A Figura 2 mostra o MAPE por país: Chile, Suriname, Uruguai e Equador concentram os maiores erros, e Chile e Suriname dobram de erro com clima. São países

de produção menor ou mais variável, o mesmo padrão relatado no artigo original e uma limitação conhecida do MAPE.

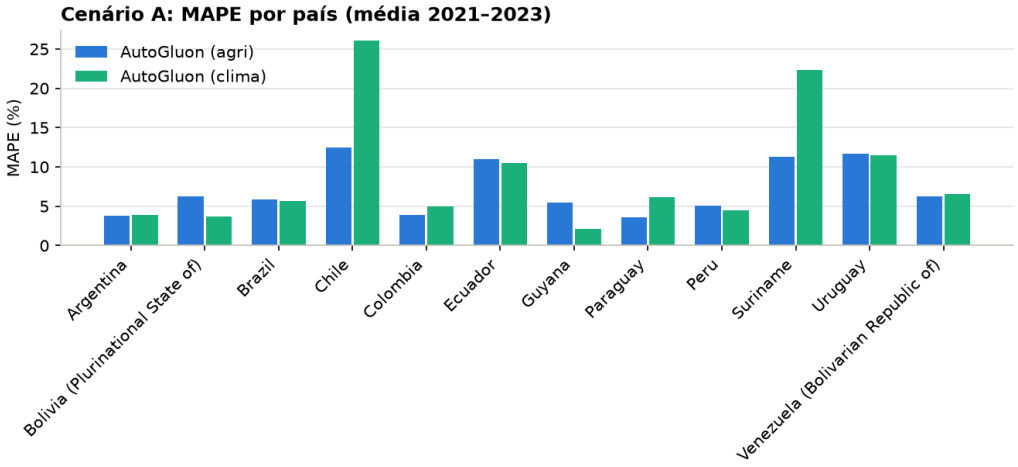


Figura 2: MAPE do AutoGluon por país (Cenário A, média 2021–2023).

5 Comparação com o artigo original

A Tabela 4 e a Figura 3 consolidam o MAPE do AutoGluon e dos modelos manuais do artigo original nos quatro cenários.

Tabela 4: Comparação de MAPE (%): AutoGluon (AutoML) versus modelos manuais do artigo original.

Cenário	Atributos	LR	SVR	XGBoost	AutoGluon
Holdout 2021–2023	agrícolas	32,38	121,15	13,72	**7,20**
Holdout 2021–2023	+ clima	**2,13**[*]	13,00[*]	8,79[*]	8,99
CV $k = 5$	agrícolas	34,87	137,23	12,47	**5,05** $\pm$ 0,48
CV $k = 5$	+ clima	34,60	121,00[†]	11,30	**6,55** $\pm$ 1,29

[*]Ver aproximação na Tabela 1. [†]O artigo relata apenas "superior a 120%" para este valor.

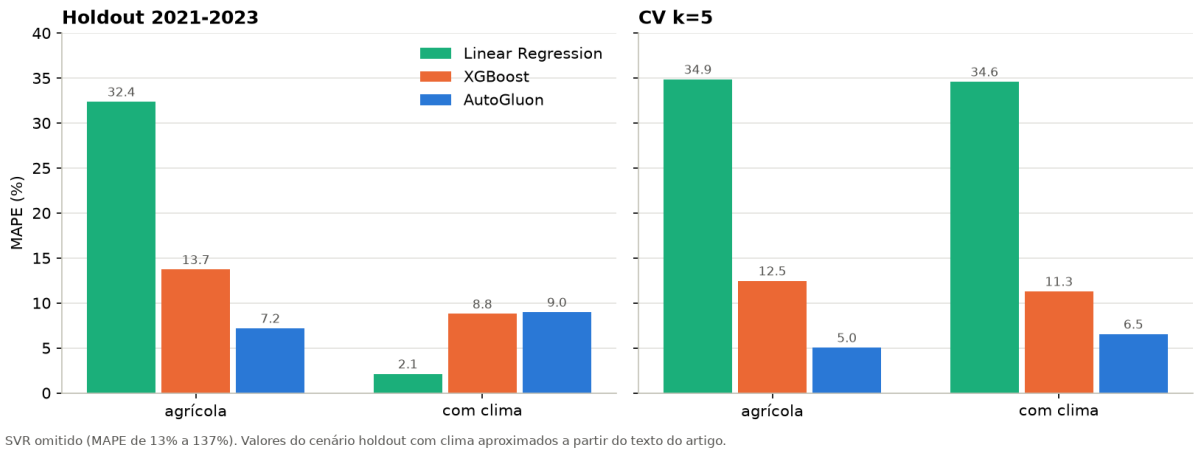


Figura 3: MAPE do AutoGluon versus modelos manuais do artigo original, por cenário (SVR omitido).

O AutoGluon supera o XGBoost manual em três cenários:

- no holdout agrícola, com quase metade do erro (7,20% contra 13,72%);
- na validação cruzada, nos dois conjuntos de atributos, com menos da metade do erro.

No holdout com clima, fica empatado com o XGBoost e atrás da Regressão Linear do artigo. Esses dois valores, porém, são aproximações extraídas do texto, e o 2,13% da Regressão Linear não se reproduz com uma Regressão Linear padronizada nos mesmos dados (cerca de 25%).

6 Discussão crítica

Vantagens.

- Não há busca manual de modelo nem de hiperparâmetros: as decisões do grupo se resumem ao preset e ao orçamento de tempo, ambos justificados empiricamente.
- O *bagging* e o *stacking* trouxeram ganhos consistentes mesmo com 120 linhas de treino.
- A ferramenta é auditável: o *leaderboard* com erro de teste por modelo, os pesos do ensemble e a importância por permutação permitem entender a solução.

Custo computacional. O Cenário A leva cerca de 2 minutos por conjunto de atributos. O notebook completo, com 24 treinos (incluindo sensibilidade, sementes e validação cruzada), leva cerca de 30 minutos numa CPU de notebook. A predição é instantânea.

Limitações.

- **Teste pequeno.** São 36 pontos de teste, e a variação entre sementes tem a mesma ordem das diferenças entre presets.
- **Semente parcial.** A semente variou os modelos, mas não a divisão dos folds do *bagging*.
- **Clima não ajudou.** As variáveis climáticas pioraram levemente o resultado nos dois cenários, ao contrário do que o artigo sugere para países com maior variabilidade climática.

- **Menos interpretável.** O ensemble final é menos interpretável que um único XGBoost: a inspeção mostra a sua composição, mas não uma regra simples.
- **Validação cruzada otimista.** A validação cruzada aleatória (Cenário B) mistura anos e é mais otimista que o holdout temporal. A limitação também vale para o artigo, que usa o mesmo protocolo.

7 Conclusão

Usamos os dados e a configuração experimental do artigo original e automatizamos a seleção de modelos, os hiperparâmetros e a combinação deles. Comparando por MAPE, o AutoGluon superou o XGBoost manual em três dos quatro cenários replicados e empatou no quarto. Ficou sempre à frente do SVR e, exceto no holdout com clima, da Regressão Linear.

A inspeção do processo mostrou de onde vem o ganho: do ensemble com *bagging* e *stacking*, com o Extra Trees como base, e não de hiperparâmetros especiais. A área colhida é, de longe, o atributo mais informativo.

Como próximos passos, sem exigir dados adicionais, ficam:

- variar também a divisão dos folds;
- usar uma validação temporal dentro do AutoGluon, para que a seleção de modelos reflita a previsão do futuro;
- testar a generalização por país com leave-one-country-out.

Referências

Nick Erickson, Jonas Mueller, Alexander Shirkov, Hang Zhang, Pedro Larroy, Mu Li, and Alexander Smola. AutoGluon-Tabular: Robust and accurate AutoML for structured data. *arXiv preprint arXiv:2003.06505*, 2020.

FAOSTAT. Crops and livestock products. `https://www.fao.org/faostat`, 2025. Acessado em 25 set. 2025.

Renan Grion. mlarrozprevisao: códigos, dados e experimentos. `https://github.com/rgrion/mlarrozprevisao`, 2026. Acessado em 30 ago. 2026.

Renan Grion, Ana Bari Koifman, Laura O. Moraes, and Mariana Simoes Larraz Ferreira. Predictive modeling of rice production in south america using machine learning. In *Anais do XXII Simpósio Brasileiro de Sistemas de Informação (SBSI 2026)*, pages 577–596, Vitória/ES, 2026. SBC. doi: 10.5753/sbsi.2026.248573.

Paul W. Stackhouse, C. H. Whitlock, W. S. Chandler, J. M. Hoell, T. Zhang, D. Westberg, A. Hoell, B. Macpherson, and J. C. Mikovitz. POWER release: NASA prediction of worldwide energy resources. Technical report, NASA, 2018.